Transcripción del vídeo La IA fiable es crucial para la empresa

Cuando hablamos de confianza en la IA, se suelen mencionar estos cinco pilares: imparcialidad, solidez, privacidad, explicabilidad y transparencia. ¿Qué significa todo esto?

Tiene razón, Aishwarya. En este momento solemos hablar de cinco pilares diferentes, pero hay que tener en cuenta que se trata de un área en rápida evolución. Es un campo que cambia con rapidez. Actualmente solemos hablar de imparcialidad, solidez, privacidad, explicabilidad y transparencia. Hablemos brevemente de cada uno de ellos.

La imparcialidad, obviamente, es para asegurarse de que los modelos no se comportan de una manera sesgada. En realidad, los retos pueden empezar mucho antes de que se construya un modelo. Se podría entender si los propios datos están sesgados. ¿Cómo se afronta este problema? Cuando se construye un modelo, ¿cómo se garantiza que el modelo no está dando sistemáticamente una ventaja o una desventaja a un determinado grupo? Y la definición del grupo varía según el sector, según el caso de uso, puede basarse en atributos confidenciales como la edad y el sexo y el origen étnico, pero puede no limitarse a ninguno de ellos. Hay que asegurarse de que el sistema no favorece injusta y sistemáticamente a unos en detrimento de otros.

En cuanto a la solidez, queremos asegurarnos de que los modelos se comportan correctamente en condiciones excepcionales. ¿Cómo nos podemos asegurar de que el rendimiento del modelo será bueno a lo largo del tiempo? ¿Qué ocurre con el desvío efectivo de datos? Por ejemplo, en el contexto de la pandemia, sabemos que el comportamiento de los clientes ha cambiado, las pautas de comportamiento de los clientes han cambiado, los puntos de contacto con los clientes han cambiado. ¿Sigue comportándose su modelo como se esperaba o, si no es así, puede al menos entender cómo está cambiando el comportamiento del modelo, cómo se están desviando los datos, cómo se está desviando la precisión, etc.?

Por lo que respecta a la privacidad, ¿puede garantizar que el modelo, los datos, el modelo que se crea a partir de ese modelo, la información que se obtiene de ese modelo son propiedad del creador del modelo y que tiene control sobre todos ellos? ¿Y cómo hacerlo, no solo en términos de consumo de los resultados del modelo, sino a lo largo de todo el ciclo de vida? ¿Cómo asegurarse de que se cumplen las reglas de protección de datos en las fases de creación, validación y control del modelo?

La explicabilidad es probablemente bastante obvia. Cómo se puede explicar el comportamiento de un modelo. Por qué a alguien se le ha aprobado un préstamo y a otro no. Cuando una persona se presenta a un puesto de trabajo y es seleccionada, pero otra con cualificaciones muy similares que también se ha presentado es rechazada, ¿puede explicar el comportamiento al usuario final o a un responsable de la toma de decisiones?

Transparencia: quiere poder inspeccionar todo sobre un modelo. ¿Es capaz de entender todos los hechos relacionados con el modelo? Quién lo ha creado, qué datos se han utilizado, qué algoritmos, qué paquetes se utilizan, quién lo ha aprobado, quién lo ha validado. Todos estos aspectos del modelo, los hechos sobre el modelo, deben estar fácilmente disponibles. Al igual que cuando compra un producto de alimentación, que tiene una etiqueta con información nutricional, cuándo se fabricó, dónde se fabricó, todo eso. En el caso de un modelo, se debería poder acceder a los datos de ese modelo rápidamente.

Yo diría que estos son los pilares fundamentales de una IA fiable. El reto consiste en garantizar que todo esto pueda hacerse de forma sistemática, independientemente de las herramientas que se utilicen para crear los modelos y de dónde se desplieguen.